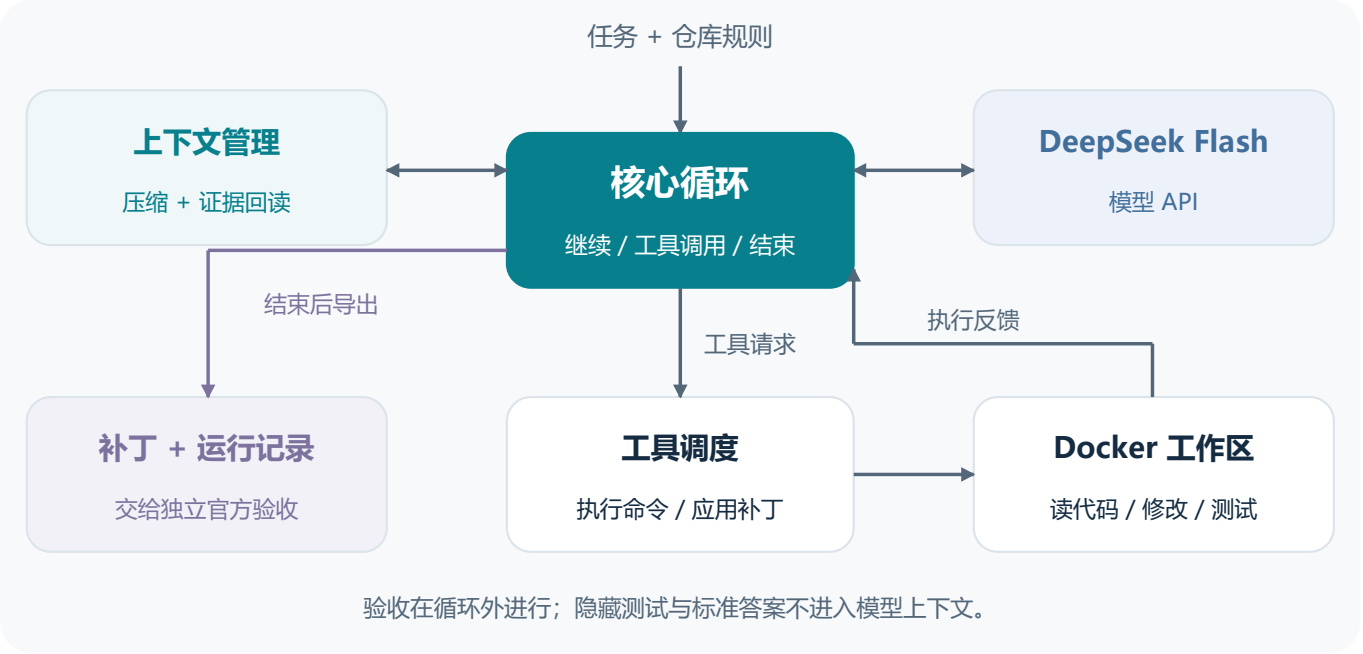
最小 Coding Agent

把任务变成补丁：自己实现循环与状态管理，复用模型和执行组件。

目标：在独立工作区中读代码、修改、运行测试并交付补丁。核心循环、上下文管理和工具调度自行实现；模型 SDK、补丁库与 Docker 复用现成组件。

01 五个组件，一条反馈循环



验收在循环外进行；隐藏测试与标准答案不进入模型上下文。

02 压缩上下文，不丢任务与工具状态

Anchor	原始任务与规则保持不变。
Checkpoint	记录定位、修改、验证状态、未解决问题与下一步。
近期完整回合	保留模型调用与全部工具结果，不能拆散配对。
外置 Evidence	有界保存原始输出，按 ID 分页回读；截断如实标记。

先用**未清理的历史**生成候选摘要，再检查格式、证据引用、真实工具状态和输入预算；**全部通过才替换。**失败保留旧历史并受控停止，不重放写操作。引用存在并不保证摘要语义全部正确。

主工作流 定位问题 → 应用补丁 → 运行相关测试 → 检查差异 → finish

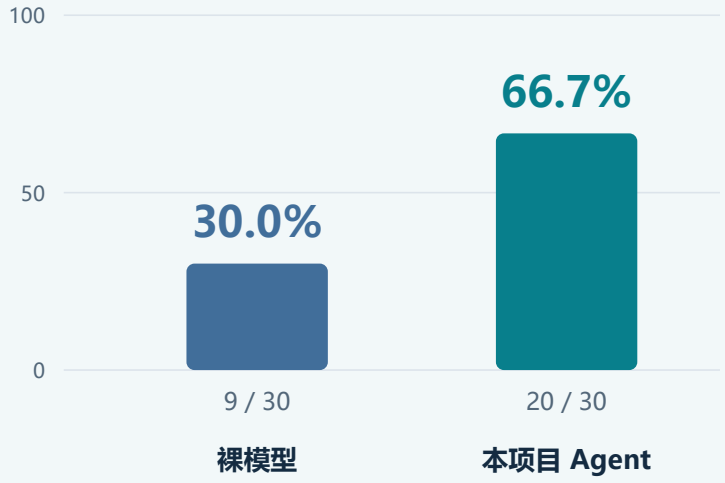
只围绕未解决问题继续；不要求全仓测试全部通过，剩余异常和未运行测试需说明。finish 是完成声明，修复正确性由循环外的官方验收判断。

实测效果与结论边界

本地系统对照与外部官方参考分区展示，不跨模型、跨题集排名。

本地同题对照

DeepSeek Flash · SWE-bench Lite 30



动作 / 裸模型 high；摘要 none

官方公开参考

Claude Opus 4.6



单次尝试 · 2026-02-17

右侧来源：SWE-bench 官方实验记录；推理 effort 未注明。不同模型、题集和运行设置，75.6% 仅作背景参考，不代表本地复现或同条件对比。

+11 题
本地额外解决

+36.7 pp
本地解决率增量

1.14M → 12.49M
裸模型 → Agent 总 token

03 如何理解这组结果

同题，但算力不等。裸模型使用固定检索上下文、单次生成，无工具或测试反馈。Agent 可多轮探索与修正，每题上限为 300 动作轮、5M 累计 token、900 秒循环时间；因此不能将增益单独归因于压缩或某条提示。
开发子集，不是完整榜单。30 题按任务 ID 升序取自 Lite，含 6 道 Astropy、24 道 Django。这是已用于开发的固定子集，不是随机、未见样本或完整 300 题。失败与空补丁仍计入分母。
仍有容量边界。C 版工具事实会累积。30 题中有 11 题因压缩失败停止，其中 6 题为空补丁。容量或校验都可能造成停止，不能一概归为模型能力不足。

下一步：将工具事实纳入有界压缩，再用固定版本、同题同预算验证长任务稳定性与修复效果。

数据与方法：项目逐题记录 | SWE-bench 官方 Claude 实验记录